Prévision horaire de la consommation électrique en France métropolitaine

Master 2 – Temporal Data Analysis

Lucy MARTIN **Clément CORREIA–PELTIER**

10 octobre 2026

Résumé

Ce rapport présente une chaîne complète de prévision de la consommation électrique horaire en France métropolitaine. À 14h le jour J, l'objectif est de prévoir les 24 valeurs de consommation du jour $J+1$ à partir des seules informations disponibles à cette heure. Nous comparons plusieurs familles de modèles : benchmarks naïfs (persistance $J-7$, $J-1$ an, moyenne), modèles d'apprentissage (XGBoost, Random Forest) et un ensemble pondéré. Le protocole respecte strictement la contrainte anti-fuite d'information. Le modèle final, un ensemble Random Forest + XGBoost ($\alpha = 0{,}2$), atteint une MAE de 1 449 MW et un RMSE de 1 963 MW sur la période de test (2025–2026), soit un gain de 56% par rapport au benchmark $J-7$ et un ratio de 1,13× par rapport à la prévision $J-1$ de RTE. Une partie critique analyse la disponibilité de l'information, la valeur ajoutée de la complexité (études d'ablation), trois cas d'échec et la robustesse du système.

Table des matières

1 Formulation du problème **3**
- 1.1 Objectif . . . 3
- 1.2 Contraintes d'information . . . 3

2 Données et préparation **3**
- 2.1 Sources . . . 3
- 2.2 Traitement . . . 3

3 Méthodologie **4**
- 3.1 Découpage chronologique . . . 4
- 3.2 Variables explicatives . . . 4
- 3.3 Modèles comparés . . . 5
- 3.4 Modélisation régionale et agrégation spatiale . . . 5
- 3.5 Protocole d'évaluation . . . 5

4 Résultats **6**
- 4.1 Comparaison globale . . . 6
- 4.2 Sélection du coefficient de pondération . . . 6
- 4.3 Analyse par saison . . . 6
- 4.4 Analyse par type de jour . . . 7
- 4.5 Importance des variables . . . 7
- 4.6 Comparaison avec la somme des modèles régionaux . . . 7

5 Audit critique **8**
5.1 Disponibilité de l'information 8
5.2 Valeur ajoutée de la complexité 8
5.3 Complexité spatiale : le cas des modèles régionaux 9
5.4 Analyse de trois cas d'échec 10
5.5 Robustesse et conditions d'utilisation 10

6 Usage des agents conversationnels **10**

7 Perspectives **11**
7.1 Enrichissement des variables explicatives 11
7.2 Modélisation spécifique des pointes 12
7.3 Architectures alternatives 12
7.4 Post-traitement des prédictions 13
7.5 Granularité spatiale 13

8 Conclusion **13**

1. Formulation du problème

1.1 Objectif

On souhaite prévoir, à 14h du jour J, les 24 valeurs horaires de la consommation électrique du jour $J+1$:

$$\hat{C}_{J+1,0}, \hat{C}_{J+1,1}, \ldots, \hat{C}_{J+1,23}. \tag{1}$$

1.2 Contraintes d'information

Deux contraintes structurent le protocole :

- **Aucune donnée observée après 14h le jour** J ne peut être utilisée comme variable explicative.
- **La météo observée de** $J+1$ n'est pas connue à 14h le jour J.
  - *Scénario opérationnel* : la météo utilisée est celle disponible à 14h (observation du jour J et prévisions).

2. Données et préparation

2.1 Sources

Consommation électrique. Les données proviennent d'éCO2mix, publié par RTE et accessible via l'API ODRE. Nous utilisons deux jeux de données complémentaires :

- `eco2mix-national-cons-def` (consolidé et définitif, 2012 à quelques semaines en arrière) ;
- `eco2mix-national-tr` (temps réel, dernières semaines).

Après fusion avec priorité au consolidé, nous disposons d'une série horaire couvrant 2012 à aujourd'hui (environ 129 000 observations après passage au pas horaire).

Météo. Les observations proviennent des données climatologiques de base de Météo-France. 22 départements métropolitains sont retenus et agrégés en une série nationale, pondérée par la population INSEE. Les indicateurs dérivés (degrés-jours de chauffage HDD, moyennes glissantes) sont calculés au pas journalier.

Calendrier. Les variables calendaires (heure, jour de la semaine, mois, week-end, jours fériés) sont construites par le groupe. La liste des jours fériés (fixes et mobiles) couvre la période 2010–2027.

2.2 Traitement

Passage au pas horaire. Seules les observations strictement à HH:00 sont conservées. Aucune moyenne entre demi-heures, aucune interpolation. Le passage à l'heure d'hiver est traité en conservant les deux occurrences de 02h00 en UTC.

Détection des anomalies. Les journées ne contenant pas 24 heures complètes sont exclues. Les doublons physiques (même timestamp UTC) sont supprimés.

Contrôle du périmètre. Toutes les observations sont vérifiées : périmètre France, pas d'observation nulle ou négative.

3. Méthodologie

3.1 Découpage chronologique

Le découpage respecte strictement l'ordre temporel. Nous avons testé quatre stratégies successives. Le split retenu est le suivant :

Table 1 – Découpage chronologique retenu (Split 2).

Jeu	Période	Durée
Train	2012-12-31 → 2023-12-31	≈ 11 ans
Validation	2024-01-01 → 2024-12-31	1 an
Test	2025-01-01 → 2026-12-31	≈ 1,75 an

Ce découpage présente plusieurs avantages :

— le train inclut les régimes pré-COVID, COVID et post-COVID ;

— la validation couvre les quatre saisons ;

— le test couvre deux hivers et deux étés, ce qui limite le risque d'évaluation sur une seule saison.

Comparaison avec les autres splits testés. Nous avons testé quatre stratégies de découpage :

Table 2 – Comparaison des stratégies de découpage testées.

Split	Train	Validation	Test	MAE	Biais
1	2012–2022 (70 %)	2022–2024 (15 %)	2024–2026 (15 %)	1,559	706
2	**2012–2023**	**2024**	**2025–2026**	**1449**	**+408**
3	2018–2025.06	2025.07–2025.12	2026	1,428	−26
4	2012–2024.10	2024.10–2025.10	2025.10–2026.10	1,510	328

Les splits 3 et 4 réduisent le biais mais dégradent la détection des pics (taux pic correct respectivement 58,3 % et 57,1 %, contre 64,7 % pour le Split 2). Le Split 2 offre le meilleur compromis entre MAE, biais et robustesse sur les pics.

3.2 Variables explicatives

19 variables sont utilisées, réparties en cinq catégories :

Table 3 – Variables explicatives utilisées.

Catégorie	Variables
Historique de consommation	`consommation_j7`, `consommation_j1an`
Calendrier	`heure`, `jour_semaine`, `mois`, `weekend`, `est_ferie`
Températures	`temperature_moyenne`, `temperature_min`, `temperature_max`, `amplitude_thermique`
Degrés-jours	`HDD_moyen`, `HDD_min`, `HDD_max`
Moyennes glissantes	`TM_3j`, `TM_7j`, `HDD_3j`, `HDD_7j`
Froid	`duree_gel_min`

Toutes ces variables sont disponibles à 14h le jour J (voir tableau 10).

3.3 Modèles comparés

Benchmarks naïfs.

— $J-7$: consommation du même jour de la semaine précédente, même heure.

— $J-1$ **an** : consommation de la même date de l'année précédente, même heure.

— **Moyenne** : moyenne des deux précédents.

Modèles d'apprentissage.

— **XGBoost** : gradient boosting. Hyperparamètres optimisés par grid search sur la validation : `learning_rate` = 0,03, `max_depth` = 8, `min_child_weight` = 5, `subsample` = 0,6, `colsample_bytree` = 0,8, `gamma` = 0,1, `reg_alpha` = 0,1, `reg_lambda` = 1,0. Arrêt précoce sur la validation (patience 100).

— **Random Forest** : 300 arbres, feuilles minimales de 2, `max_features = sqrt`.

— **Ensemble** : moyenne pondérée $\alpha \cdot RF + (1-\alpha) \cdot XGB$, avec α choisi sur la validation.

Référence externe. La prévision J-1 de RTE, récupérée via l'API éCO2mix temps réel, sert de référence haute.

3.4 Modélisation régionale et agrégation spatiale

En complément du modèle national, nous avons exploré une approche *spatiale* : entraîner un modèle par région métropolitaine (12 régions), puis agréger les prédictions individuelles par simple somme pour reconstruire une prévision nationale. L'objectif est double :

— **Tester si une décomposition spatiale apporte un gain** en capturant les dynamiques locales (météo régionale, structure industrielle, comportements de consommation) que l'agrégation nationale lisse.

— **Produire une visualisation opérationnelle** : une carte interactive des prévisions régionales est intégrée au dashboard Streamlit du projet (onglet « Carte régionale »).

Données régionales. Nous utilisons deux sources complémentaires :

— **Consommation régionale** : les datasets `eco2mix-regional-cons-def` (consolidé définitif) et `eco2mix-regional-tr` (temps réel), publiés par RTE.

— **Météo régionale** : pour chaque région, nous sélectionnons *un département de référence*. La météo du département est utilisée comme approximation de la météo régionale.

Protocole. Chaque modèle régional est entraîné selon la même structure que le modèle national avec un même split, mêmes hyperparamètres et mêmes 19 features. La prévision nationale *par somme* est obtenue en additionnant les 12 prévisions régionales.

3.5 Protocole d'évaluation

Les modèles sont comparés sur le *même test*, avec la *même information disponible*. Les métriques utilisées sont : MAE, RMSE, biais, erreur sur le pic journalier, erreur sur l'heure du pic, erreur sur la consommation journalière totale. Les performances sont ventilées par saison et par type de jour (ouvré, week-end, férié).

4. Résultats

4.1 Comparaison globale

Table 4 – Performances sur le test (Split 2, 2025–2026). Toutes les valeurs en MW.

Modèle	MAE	RMSE	Biais
Ensemble RF + XGBoost ($\alpha = 0{,}2$)	**1449**	**1963**	**+408**
XGBoost seul	1,469	1,988	431
Random Forest seul	1,528	2,104	376
Benchmark moyenne	3,120	4,343	–
Benchmark $J-7$	3,333	4,899	
Benchmark $J-1$ an	4,073	5,604	
RTE $J-1$ (référence)	1,280	1,601	

L'ensemble RF + XGBoost obtient la meilleure performance parmi les modèles que nous avons entraînés. Il surpasse le benchmark $J-7$ de 56.5 % et reste à un ratio de 1,13× de la prévision RTE. Ce ratio est cohérent avec la littérature : RTE dispose de données plus fines, de prévisions météo professionnelles et de comptage temps réel.

4.2 Sélection du coefficient de pondération

L'ensemble optimise α (poids du Random Forest) sur la validation. Le tableau suivant résume les résultats pour les principales valeurs de α :

Table 5 – Recherche du coefficient de pondération de l'ensemble (validation 2024).

α	MAE val.	RMSE val.
0 ,0(XGBseul)	1,994	2,659
0 ,1	1,991	2,658
0,2	**1990**	**2660**
0 ,3	1,991	2,666
0 ,4	1,995	2,676
0 ,5	2,001	2,688
1 ,0(RFseul)	2,063	2,803

Le coefficient retenu est $\alpha = 0{,}2$: la contribution majoritaire vient de XGBoost, mais le Random Forest apporte une légère diversification qui réduit la variance.

4.3 Analyse par saison

Table 6 – MAE par saison (test).

Saison	MAE (MW)
Hiver	2,171
Printemps	1,398
Été	1,120
Automne	1,159

L'hiver concentre les erreurs les plus fortes, c'est attendu car les consommations y sont plus élevées et avec l'augmentation du chauffage lors des vagues de froid et aux épisodes de pointe. Le ratio MAE hiver/été est de 1,94×.

4.4 Analyse par type de jour

Table 7 – MAE par type de jour (test).

Type	MAE (MW)
Ouvré	1,475
Week-end	1,372
Férié	1,559

Les jours fériés sont les plus difficiles, ce qui reflète à la fois leur rareté et la spécificité de leurs profils de consommation. En effet, un jour férié en mai avec la possibilité de le transformé en pont modifie le format de la semaine et transforme en partie le vendredi en un jour de week-end, ce qui fait baisser la consommation globale de la France.

4.5 Importance des variables

Le tableau suivant présente les cinq variables les plus importantes dans le modèle XGBoost :

Table 8 – Importances des variables (XGBoost, top 5).

Variable	Importance (%)
`consommation_j7`	39,7
`HDD_max`	25,4
`temperature_max`	12,1
`HDD_moyen`	4,2
`weekend`	3,6

XGBoost concentre l'information sur trois variables qui représentent à elles seules 77 % de l'importance totale. La variable `HDD_max` (degrés-jours calculés sur la température maximale) devient la deuxième variable la plus importante, ce qui traduit que les pointes de froid sont le principal moteur des consommations élevées.

4.6 Comparaison avec la somme des modèles régionaux

Nous comparons les performances du modèle national à celles de la *somme des 12 modèles régionaux* sur la période de test.

Table 9 – Comparaison national vs somme régionale (test 2025–2026). Toutes les valeurs en MW.

Approche	MAE	RMSE	Biais	MAE pic
Modèle national (Ensemble)	1,449	1,963	408	1,426
Somme des 12 modèles régionaux	1,521	2,059	467	1,489
RTE $J-1$ (référence)	1,280	1,601		

La somme régionale est **légèrement moins précise** que le modèle national. Ce résultat peut sembler contre-intuitif (on s'attendrait à ce qu'un modèle plus fin soit meilleur), mais il s'explique par plusieurs facteurs :

— **Propagation d'erreurs** : chaque modèle régional a sa propre erreur. En sommant 12 prévisions, les erreurs s'accumulent et se compensent partiellement. Contrairement à ce qu'on pourrait espérer, les erreurs régionales sont *positivement corrélées* (une vague de froid touche simultanément plusieurs régions), donc la compensation est faible.

— **Perte de régularité par région** : les données régionales sont plus bruitées que les données nationales (agrégation d'effets locaux, industriels, événements régionaux). Un modèle régional a donc un ratio signal/bruit plus faible à apprendre.

— **Météo imparfaite** : chaque région utilise la météo d'*un seul département* de référence. Cette approximation introduit un biais systématique, en particulier pour les régions vastes (Nouvelle-Aquitaine, Occitanie) où la variabilité intra-régionale est forte.

— **Effet de moyenne implicite** : le modèle national, entraîné sur des données déjà agrégées, bénéficie implicitement d'un effet de lissage qui réduit la variance des erreurs.

5. Audit critique

5.1 Disponibilité de l'information

Table 10 – Disponibilité de chaque variable à 14h le jour J.

Variable	Source	Disponibilité	Type	Risque de fuite
`conso_j7`	éCO2mix	$J-7$	Observé	Aucun (historique)
`conso_j1an`	éCO2mix	$J-365$	Observé	Aucun (historique)
`heure`	Construite	J	Déterministe	Aucun
`jour_semaine`	Construite	J	Déterministe	Aucun
`weekend`	Construite	J	Déterministe	Aucun
`est_ferie`	Construite	J	Déterministe	Aucun
`temperature_*`	Météo-France	J	Observé à 14h	Faible
`HDD_*`	Dérivée	J	Calculée	Aucun
`TM_3j, TM_7j`	Dérivée	J	Calculée	Aucun

La question centrale est : *cette prévision aurait-elle réellement pu être calculée à 14h le jour J ?* La réponse est **oui** pour toutes les variables utilisées. Les températures proviennent d'observations du jour J disponibles à 14h, et non de la météo de $J+1$.

Nuances sur le scénario opérationnel. Nous utilisons **Open-Meteo Forecast** pour la prévision opérationnelle. Deux limites sont à signaler :

— **Agrégation spatiale** : Open-Meteo fournit la météo d'un point (Paris), alors que le modèle a été entraîné sur une moyenne nationale pondérée. Un biais systématique de 0,5 à 1°C est possible entre les deux sources.

— **Variable `duree_gel_min`** : non disponible via Open-Meteo, elle est mise à 0. Cela peut légèrement dégrader la prévision par rapport à la version entraînée.

Ces limites sont acceptables car le pipeline fonctionne de bout en bout et les prédictions restent cohérentes avec les performances observées.

5.2 Valeur ajoutée de la complexité

Nous avons conduit plusieurs études d'ablation pour évaluer l'apport de chaque groupe de variables.

Table 11 – Étude d'ablation. Impact sur la MAE du test.

Configuration	**MAE (MW)**	**Δ**
Sans variables météo	2,944	
Avec météo, sans `est_ferie`	1,703	−42 ,2 %
Avec météo et `est_ferie`	1,650	−3 ,1 %
Modèle complet (19 feat.)	**1449**	
Sans `est_ferie`	2,517	74 %*(sur les fériés)*
Sans vacances scolaires	1,458	0 ,5 %
Avec indicateur IPI	1,483	2 ,5 %
Avec pondération temporelle	1,623	0 ,9 %

Les enseignements majeurs :

- La **météo** est de loin la contribution la plus importante. Sans elle, la MAE double presque (2944 → 1703 MW, soit −42 %).
- Le `est_ferie` apporte un gain modeste sur la MAE globale (−3 %) mais **divise la MAE sur les fériés par 1,8** (4654 → 2517 MW). Son retrait fait exploser le biais sur les fériés (+2105 → +4517 MW), ce qui prouve son rôle critique sur les cas atypiques.
- Les **vacances scolaires** par zone n'apportent rien (dégradation marginale de 0,24 à 0,38 %). Explication : `consommation_j7` capture déjà implicitement les effets des vacances (si le même jour de la semaine précédente était en vacances, la consommation de référence est déjà ajustée).
- L'**IPI** (indice de production industrielle) dégrade la MAE (+2,5 %) mais améliore la détection des pics (+2,2 pts). Décision : rejeté pour la MAE globale.
- La **pondération temporelle** des observations (favoriser les récentes) ne réduit pas le biais (+687 → +701 MW) et dégrade la MAE (+0,9 %). Le biais n'est donc pas causé par une dérive temporelle.

5.3 Complexité spatiale : le cas des modèles régionaux

Nous avons montré (tableau 9) que la somme de 12 modèles régionaux est légèrement moins précise que le modèle national, alors qu'elle mobilise *12 fois plus de calcul*.

Interprétation. Cet écart de performance met en évidence trois limites structurelles de l'approche régionale telle que nous l'avons implémentée :

1. **Volume de données par région insuffisant** : chaque région dispose de 12 fois moins d'observations que la France entière. Pour 12 ans d'historique, cela représente ≈ 105 000 observations régionales contre ≈ 1,26 million au national. Les modèles régionaux sont donc mécaniquement moins bien entraînés.
2. **Représentativité météo limitée** : nous utilisons *un seul département* comme proxy de la météo régionale. Pour des régions comme Occitanie ou Nouvelle-Aquitaine, cette approximation est grossière. Utiliser une moyenne pondérée de plusieurs départements par région réduirait ce biais.
3. **Structure de dépendance spatiale ignorée** : les régions ne sont pas indépendantes. Par exemple, une vague de froid traverse le pays d'ouest en est.

Leçon méthodologique. Augmenter la finesse spatiale dégrade le ratio signal/bruit quand la quantité de données par sous-unité devient insuffisante.

5.4 Analyse de trois cas d'échec

Cas 1 : 25 décembre 2024 – Noël. La MAE journalière atteint 7 171 MW. Le modèle prédit un pic à 66 966 MW pour un pic réel de 56 227 MW. La cause principale est un *profil atypique non capturé*, en effet, Noël combine un jour férié, une fin d'année et une météo douce (température moyenne 7,07°C, $HDD = 10{,}9$). Le modèle a tendance à surestimer massivement la consommation sur ce type de jour. Ce cas relève d'une **limite du modèle**, la variable `est_ferie` est binaire et ne distingue pas les profils très différents (Noël vs 1er mai).

Cas 2 : 21 janvier 2025 – vague de froid. La MAE journalière atteint 7 007 MW. Le pic réel est de 81 804 MW, prévu à 84 573 MW. La température moyenne réelle est de 2,53°C avec $HDD = 15{,}47$. Le modèle surestime la consommation de 2 769 MW sur le pic. Ce cas illustre une **limite des données météo** car la prévision à J-1 avait un biais froid, et le modèle a amplifié la consommation attendue.

Cas 3 : 22 novembre 2025 – vague de froid précoce. La MAE journalière dépasse 6 231 MW, avec un *biais négatif* (−149 546 MWh sur la journée). Température observée : 0,03°C. Ce cas est rare, une vague de froid précoce (novembre) est peu fréquente dans l'entraînement (2012–2023). Le modèle *sous-estime* cette journée, à contre-courant de sa tendance générale. Ce cas combine une **rupture de régime** (froid inhabituel en novembre) et une **limite du protocole**, le modèle n'a pas assez d'exemples de novembre froid pour bien généraliser.

5.5 Robustesse et conditions d'utilisation

- **Stabilité du classement.** L'ensemble RF + XGBoost reste devant XGBoost seul et Random Forest seul sur tous les sous-échantillons. Le classement est robuste.
- **Sensibilité saisonnière.** L'hiver est systématiquement plus difficile que l'été (1,94×). Ce comportement est cohérent avec la littérature.
- **Biais résiduel.** Le modèle surestime systématiquement de +408 MW en moyenne (Split 2). Une correction naïve du biais dégrade les performances sur les pics, ce qui décourage un post-traitement brut.
- **Biais hivernal.** Le biais est particulièrement élevé en hiver (+1777 MW) sur le Split 1. Cela suggère une surestimation structurelle de la consommation hivernale sur la période de test, possiblement liée à la baisse récente de la consommation (sobriété énergétique, prix de l'électricité) non capturée par l'entraînement.
- **Heures de transition.** Les heures 4h–5h et 7h–8h sont les plus difficiles à prédire (MAE respectivement 1374 et 1843 MW).

Conditions déconseillées. Nous déconseillons l'utilisation du système :

- lors d'épisodes météorologiques exceptionnels (vagues de froid précoces, canicules) où les prévisions météo elles-mêmes sont incertaines.
- pour anticiper des ruptures structurelles (grèves, fermetures industrielles).
- pour des horizons au-delà de J+1, sans re-calibration.

6. Usage des agents conversationnels

Conformément au sujet, nous documentons trois exemples d'usage.

Exemple 1 : proposition conservée. **Tâche demandée.** Implémenter une fonction de calcul des degrés-jours de chauffage (HDD) à partir des températures journalières.
Proposition obtenue. Une fonction vectorisée avec NumPy, gérant les valeurs manquantes et les températures négatives.
Décision. Conservée après vérification manuelle sur 10 jours tests. Le calcul correspond à la définition classique $HDD = \max(0, 18 - T_{moy})$.
Vérification. Comparaison avec un calcul manuel et la documentation de l'INSEE.

Exemple 2 : proposition modifiée. **Tâche demandée.** Écrire la fonction de construction des features $J-7$ et $J-1$ an.
Proposition obtenue. Une fonction utilisant `pandas.DateOffset(years=1)` pour $J-1$ an.
Décision. Modifiée. L'agent n'avait pas pris en compte le cas du 29 février. Nous avons ajouté une gestion explicite du cas avec un fallback sur le 28 février, et un test de non-régression.
Vérification. Jeu de tests couvrant 2020 (année bissextile) et 2021.

Exemple 3 : erreur détectée. **Tâche demandée.** Implémenter la lecture des données éCO2mix avec la bibliothèque `requests`.
Proposition obtenue. Un code qui télécharge le CSV complet sans filtre, puis filtre côté client.
Erreur détectée. Le code mettait plus de 3 minutes à s'exécuter et saturait la mémoire. Nous avons identifié que l'API supporte un paramètre `where` côté serveur, ce qui réduit la charge de 95 %.
Décision. Rejetée puis réécrite. La nouvelle version filtre directement dans la requête HTTP.
Vérification. Comparaison des temps d'exécution (180 s vs 4 s) et vérification que les données récupérées sont identiques.

7. Perspectives

Le modèle développé dans ce projet atteint des performances solides (MAE $\approx$ 1 449 MW, ratio 1,13× par rapport à la prévision J-1 de RTE), mais plusieurs pistes d'amélioration restent ouvertes. Nous les classons en cinq catégories : enrichissement des variables explicatives, modélisation de la pointe, architectures alternatives, post-traitement des prédictions, et granularité spatiale.

7.1 Enrichissement des variables explicatives

Le modèle utilise aujourd'hui un encodage *binaire* des jours fériés (`est_ferie`) et des weekends, ce qui est une simplification au regard de la complexité des comportements de consommation.

— **Encodage fin des jours fériés** : les jours fériés n'ont pas tous le même effet. Un *pont* (vendredi après un jeudi férié, lundi après un dimanche férié) a un profil proche d'un weekend, alors qu'un 1er mai ou un 25 décembre a un profil très atypique. La veille d'un jour férié est également particulière (activité réduite, mais pas nulle). Ajouter des indicateurs `est_pont`, `est_veille_ferie`, `type_ferie` (fixe / mobile / religieux) permettrait au modèle de distinguer ces situations. Notre split des données contient 45 jours fériés, dont beaucoup sont précédés ou suivis de ponts, cette amélioration pourrait faire un peu baisser la MAE les jours fériés.

— **Vacances scolaires par zone** : l'ajout d'un indicateur de vacances par zone, non pas binaire mais par exemple pondéré par la population scolaire pourrait aussi améliorer les performances sur ces périodes. Le sujet est d'autant plus intéressant que les vacances d'hiver et de printemps sont décalées entre zones, ce qui crée des motifs de consommation distincts sur plusieurs semaines. Nous l'avons testé et cela a augmenté le biais, il y a peut-être une meilleure façon de transmettre l'information des vacances qu'en partageant de façon binaire si une zone est en vacances.

— **Événements exceptionnels** : les grèves (transport, raffineries, secteur public) et les événements sportifs majeurs (Coupe du monde, Jeux Olympiques, matchs de l'équipe de France) modifient ponctuellement la consommation. Une grève des transports peut faire baisser la consommation de bureau et augmenter la consommation résidentielle. Un match de l'équipe de France peut créer un pic de consommation à la mi-temps. Ces événements sont difficilement prévisibles, mais certains sont connus à l'avance (matchs programmés, préavis de grève). Les intégrer comme features binaires est une piste à coût faible tant qu'on peut trouver des api correspondantes à nos besoins.

— **Prévisions météo d'ensemble** : pour prédire la consommation j+1, nous utilisons actuellement une seule prévision météo (Open-Meteo), qui peut se tromper. Une approche plus robuste consiste à utiliser un ensemble de prévisions (par exemple, 10 scénarios issus de modèles météo différents) et à calculer la moyenne et l'écart-type de la consommation prévue. Cela permet non seulement d'améliorer la précision moyenne, mais aussi de quantifier l'incertitude sur la prévision finale, ce qui est très utile pour la gestion de réseau.

7.2 Modélisation spécifique des pointes

L'analyse des erreurs a montré que notre modèle sous-estime les pics (biais pic = −85 MW) et identifie l'heure de pointe dans seulement 64,7 % des cas.

— **Modèle dédié à la pointe** : entraîner un second modèle spécifiquement sur les heures de pointe (7h–9h et 17h–20h), avec des features enrichies (température ressentie, gradient de température sur 1h, indicateurs d'événements). Ce modèle serait utilisé en complément du modèle général, avec une pondération plus forte sur les heures de pointe. On peut attendre une amélioration du taux de pic correct.

— **Modèles par heure** : au lieu d'un modèle global avec `heure` comme feature, entraîner 24 modèles spécialisés (un par heure). Chaque modèle apprendrait les motifs spécifiques de son heure. Cette approche est classique en prévision de charge et donne souvent de meilleurs résultats, au prix d'une complexité accrue car il y aurait 24 modèles à maintenir.

— **Modèles par saison** : entraîner 4 modèles (hiver, printemps, été, automne) permettrait à chaque modèle d'apprendre les relations spécifiques à sa saison. L'hiver est dominé par le chauffage, l'été par la climatisation et l'éclairage. Le gain attendu pourrait être significatif sur les saisons extrêmes, mais la validation croisée serait plus complexe. Cette approche pose le problème du choix des dates de chaque saison. En effet, avec le réchauffement climatique, on peut observer des canicules dès les mois d'avril et de mai, des températures élevées en automne, ou d'autres décalages de saison. De plus, ces changements climatiques étant de plus en plus extrêmes avec le temps, les données historiques que nous avons ne permettent pas d'apprendre ces évolutions.

7.3 Architectures alternatives

Notre modèle final est un ensemble Random Forest + XGBoost. Plusieurs architectures méritent d'être testées.

— **LightGBM** : alternative à XGBoost, souvent plus rapide et aussi précise sur des données tabulaires. Il gère nativement les features catégorielles et utilise un algorithme de croissance d'arbre différent (leaf-wise vs level-wise). Le gain potentiel pourrait être relativement faire, de l'ordre de quelques pourcents de MAE au mieux, avec un temps d'entraînement potentiellement réduit.

— **Modèles de séries temporelles profondes** : les architectures LSTM, GRU et TFT (Temporal Fusion Transformer) sont conçues pour capturer des dépendances temporelles longues. Un LSTM pourrait apprendre des motifs que les arbres ne captent pas (par exemple, l'effet cumulé de plusieurs jours de froid). Le gain attendu est incertain sur ce type de données (les

modèles à base d'arbres dominent souvent en prévision de charge tabulaire), mais l'exploration est scientifiquement intéressante.

— **Modèles hybrides** : combiner un modèle statistique classique (SARIMAX) avec un modèle d'apprentissage automatique (XGBoost) permet souvent de capturer à la fois les composantes linéaires (tendance, saisonnalité) et les non-linéarités. Le gain attendu est de -1 à -3 % de MAE.

7.4 Post-traitement des prédictions

Le post-traitement est une étape souvent négligée, mais à fort potentiel.

— **Correction du biais** : notre modèle a un biais résiduel de +408 MW (surestimation). Une correction naïve (soustraction du biais moyen) serait efficace en moyenne mais détériorerait les performances sur les pics, car le biais est plus fort en hiver et sur les heures de pointe. Une correction conditionnelle (par saison, par type de jour, par tranche horaire) serait plus robuste. Le gain attendu est une réduction du biais de 50 à 70 %, sans dégrader la MAE.

— **Calibration des pics** : entraîner un modèle spécifique sur les résidus des pics (écart entre pic prévu et pic réel), puis ajouter cette correction au modèle principal. Le gain attendu est une réduction de 15 à 25 % de l'erreur sur les pics.

— **Ensemble pondéré par le contexte** : au lieu d'un α fixe (0,2) pour l'ensemble RF + XGBoost, utiliser un α qui dépend du contexte (saison, type de jour, météo). Par exemple, $\alpha = 0{,}3$ en hiver et $\alpha = 0{,}1$ en été. Le gain attendu est de $-0{,}5$ à $-1{,}5$ % de MAE.

7.5 Granularité spatiale

Nous avons testé une première approche régionale qui, bien que fonctionnelle, est restée *légèrement moins précise* que le modèle national. Ce résultat ne remet pas en cause la pertinence de la décomposition spatiale, mais il ouvre plusieurs pistes pour l'améliorer.

— **Amélioration de la météo régionale.** Il faudrait utiliser plusieurs données de départements par région.

— **Modèles hiérarchiques.** Au lieu d'entraîner 12 modèles indépendants, entraîner un modèle national pour capturer la tendance commune, puis des modèles régionaux sur les résidus.

— **Modèles avec dépendance spatiale.** Les régions ne sont pas indépendantes. Un modèle de type *Graph Neural Network* (GNN) qui modélise explicitement les interactions entre régions voisines pourrait capturer les effets de propagation (vagues de froid, événements nationaux). L'apprentissage nécessiterait des données régionales à granularité plus fine (département, voire commune), ce qui dépasse le cadre actuel du projet.

— **Volume de données et profondeur temporelle.** Une limite fondamentale de l'approche régionale est le manque de données par région. Pour qu'un modèle régional atteigne la précision d'un modèle national il faudrait augmenter la profondeur temporelle.

8. Conclusion

Nous avons construit une chaîne complète de prévision horaire de la consommation électrique en France métropolitaine. Le protocole respecte strictement la contrainte opérationnelle (aucune information postérieure à 14h le jour J). Le modèle final, un ensemble Random Forest + XGBoost avec $\alpha = 0{,}2$, atteint une MAE de 1 449 MW et un RMSE de 1 963 MW sur la période de test (2025–2026), soit un gain de 56 % par rapport au benchmark $J-7$ et un ratio de 1,13× par rapport à RTE.

L'analyse critique révèle plusieurs enseignements :

— La **météo** et les **retards de consommation** sont les variables les plus utiles (+42 % et +30 % de gain respectivement).

— Un modèle à 19 features surpasse un modèle à 40 features (parcimonie).

— L'ajout de `est_ferie` réduit la MAE sur les fériés de 38 %.

— Le biais positif persistant (+408 MW) est structurel et ne se corrige pas par les hyperparamètres.

— L'hiver reste la saison la plus difficile (1,94× plus d'erreur qu'en été).

— **L'approche régionale**, a une valeur ajoutée principalement opérationnelle (visualisation cartographique, interprétabilité locale), et non une amélioration brute de la précision.

Trois types d'échec se dégagent : limites météo (vagues de froid imprévues), limites du modèle (fériés atypiques comme Noël) et ruptures de régime exceptionnelles.

Annexe : journal synthétique des usages d'agents

Tâche	Proposition	Décision	Vérification
HDD vectorisé	NumPy + gestion NaN	Conservée	Comparaison manuelle sur 10 jours
Feature $J-1$ an	`DateOffset(years=1)`	Modifiée	Tests 2020 & 2021
Lecture éCO2mix	Filtre client	Rejetée	Filtre serveur `where`, 180s → 4s
Split chronologique	70/15/15 proportionnel	Modifiée	4 splits comparés, Split 2 retenu
Optimisation α	Grid sur validation	Conservée	Recherche exhaustive 0 à 1
Ablation features	Retrait `est_ferie`	Rejetée	MAE fériés dégradée de +74%
Vacances scolaires	Ajout 3 indicateurs	Rejetée	MAE dégradée de +0,38%
Pondération temporelle	Poids linéaire croissant	Rejetée	MAE dégradée, biais inchangé

Bibliographie

— RTE, *éCO2mix* – Données de consommation électrique, https://odre.opendatasoft.com/.

— Météo-France, *Données climatologiques de base*, https://meteo.data.gouv.fr/.

— Open-Meteo, *Forecast API*, https://open-meteo.com/.

— T. Chen et C. Guestrin, *XGBoost : A Scalable Tree Boosting System*, KDD 2016.

— L. Breiman, *Random Forests*, Machine Learning, 2001.

— INSEE, *Indice de production industrielle* (utilisé en ablation puis abandonné).