Prévision horaire de la consommation électrique en France métropolitaine

Master 2 – Temporal Data Analysis

Lucy MARTIN **Clément CORREIA–PELTIER**

11 octobre 2026

Résumé

Ce rapport présente une chaîne complète de prévision de la consommation électrique horaire en France métropolitaine. À 14h le jour J, l'objectif est de prévoir les 24 valeurs de consommation du jour $J+1$ à partir des seules informations disponibles à cette heure. Nous comparons plusieurs familles de modèles (benchmarks naïfs, XGBoost, Random Forest, ensemble pondéré) selon deux scénarios météo : un **scénario opérationnel** utilisant la météo observée de $J-1$ comme proxy, strictement disponible à 14h le jour J, et un **scénario à météo parfaite** utilisant la météo observée de $J+1$, non déployable mais servant de borne supérieure de performance. Le modèle final, un ensemble Random Forest + XGBoost ($\alpha = 0{,}2$), atteint une MAE de 1 832 MW en conditions opérationnelles et 1 341 MW en météo parfaite sur la période de test (2025–2026). L'écart entre les deux scénarios (+27 % de MAE) quantifie la valeur maximale qu'apporterait une météo parfaite. Une partie critique analyse la disponibilité de l'information, la valeur ajoutée de la complexité, trois cas d'échec en conditions opérationnelles et la robustesse du système.

Table des matières

1 Formulation du problème **3**
- 1.1 Objectif . . . 3
- 1.2 Contraintes d'information . . . 3
- 1.3 Deux scénarios météo évalués . . . 3

2 Données et préparation **3**
- 2.1 Sources . . . 3
- 2.2 Traitement . . . 4

3 Méthodologie **4**
- 3.1 Découpage chronologique . . . 4
- 3.2 Variables explicatives . . . 4
- 3.3 Modèles comparés . . . 5
- 3.4 Modélisation régionale et agrégation spatiale . . . 5
- 3.5 Protocole d'évaluation . . . 6

4 Résultats **6**
- 4.1 Comparaison globale . . . 6
- 4.2 Sélection du coefficient de pondération . . . 7
- 4.3 Analyse par saison . . . 7

4.4 Analyse par type de jour 7
4.5 Importance des variables 8
4.6 Comparaison avec la somme des modèles régionaux (météo parfaite) 8

5 Audit critique **9**
5.1 Disponibilité de l'information 9
5.2 Valeur ajoutée de la complexité 9
5.3 Complexité spatiale : le cas des modèles régionaux 10
5.4 Analyse de trois cas d'échec (scénario opérationnel) 11
5.5 Robustesse et conditions d'utilisation 11

6 Usage des agents conversationnels **12**

7 Perspectives **12**
7.1 Enrichissement des variables explicatives 12
7.2 Modélisation spécifique des pointes 13
7.3 Architectures alternatives 13
7.4 Post-traitement des prédictions 14
7.5 Granularité spatiale 14
7.6 Météo opérationnelle 15

8 Conclusion **15**

1. Formulation du problème

1.1 Objectif

On souhaite prévoir, à 14h du jour J, les 24 valeurs horaires de la consommation électrique du jour $J+1$:

$$\hat{C}_{J+1,0}, \hat{C}_{J+1,1}, \ldots, \hat{C}_{J+1,23}. \tag{1}$$

1.2 Contraintes d'information

Deux contraintes structurent le protocole :

— **Aucune donnée observée après 14h le jour** J ne peut être utilisée comme variable explicative.

— **La météo observée de** $J+1$ n'est pas connue à 14h le jour J.

1.3 Deux scénarios météo évalués

Pour quantifier l'impact de la contrainte d'information, deux scénarios sont construits en parallèle. Ils partagent strictement le même protocole : mêmes splits chronologiques, mêmes hyperparamètres, mêmes 19 features, seul le millésime de la météo change.

— **Scénario opérationnel (météo $J-1$).** Les features météo sont les observations du jour $J-1$. Cette information est strictement disponible à 14h le jour J. C'est le scénario *déployable* en conditions réelles.

— **Scénario à météo parfaite (météo $J+1$).** Les features météo sont les observations du jour $J+1$ (date cible). Cette information n'est pas disponible à 14h le jour J. Ce scénario *n'est pas déployable* et sert uniquement de *borne supérieure* de performance.

L'écart de performance entre les deux scénarios borne l'apport maximal qu'une prévision météo parfaite apporterait. En conditions réelles, avec une prévision météo standard, on se situerait entre ces deux bornes.

2. Données et préparation

2.1 Sources

Consommation électrique. Les données proviennent d'éCO2mix, publié par RTE et accessible via l'API ODRE. Nous utilisons deux jeux de données complémentaires :

— `eco2mix-national-cons-def` (consolidé et définitif, 2012 fin août 2026) ;

— `eco2mix-national-tr` (temps réel, dernières semaines).

Après fusion avec priorité au consolidé, nous disposons d'une série horaire couvrant 2012 à aujourd'hui (environ 129 000 observations après passage au pas horaire).

Météo. Les observations proviennent des données climatologiques de base de Météo-France. 22 départements métropolitains sont retenus et agrégés en une série nationale, pondérée par la population INSEE. Les indicateurs dérivés (degrés-jours de chauffage HDD, moyennes glissantes) sont calculés au pas journalier.

Calendrier. Les variables calendaires (heure, jour de la semaine, mois, week-end, jours fériés) sont construites par le groupe. La liste des jours fériés (fixes et mobiles) couvre la période 2010–2027.

2.2 Traitement

Passage au pas horaire. Seules les observations strictement à HH:00 sont conservées. Aucune moyenne entre demi-heures, aucune interpolation. Le passage à l'heure d'hiver est traité en conservant les deux occurrences de 02h00 en UTC.

Détection des anomalies. Les journées ne contenant pas 24 heures complètes sont exclues. Les doublons physiques (même timestamp UTC) sont supprimés.

Contrôle du périmètre. Toutes les observations sont vérifiées : périmètre France, pas d'observation nulle ou négative.

3. Méthodologie

3.1 Découpage chronologique

Le découpage respecte strictement l'ordre temporel. Nous avons testé quatre stratégies successives. Le split retenu est identique pour les deux scénarios (il est basé uniquement sur `origine_prevision`) :

Table 1 – Découpage chronologique retenu (Split 2).

Jeu	Période	Durée
Train	2012-12-31 → 2023-12-31	≈ 11 ans
Validation	2024-01-01 → 2024-12-31	1 an
Test	2025-01-01 → 2026-10-08	638 jours

Ce découpage présente plusieurs avantages :

- le train inclut les régimes pré-COVID, COVID et post-COVID ;
- la validation couvre les quatre saisons ;
- le test couvre deux hivers et deux étés, ce qui limite le risque d'évaluation sur une seule saison.

Comparaison avec les autres splits testés. Nous avons testé quatre stratégies de découpage :

Table 2 – Comparaison des stratégies de découpage testées en météo parfaite.

Split	Train	Validation	Test	MAE	Biais
1	2012–2022 (70 %)	2022–2024 (15 %)	2024–2026 (15 %)	1,559	706
2	2012–2023	2024	2025–2026	1,449	408
3	2018–2025.06	2025.07–2025.12	2026	1,428	−26
4	2012–2024.10	2024.10–2025.10	2025.10–2026.10	1,510	328

Les splits 3 et 4 réduisent le biais mais dégradent la détection des pics (taux pic correct respectivement 58,3 % et 57,1 %, contre 64,7 % pour le Split 2). Le Split 2 offre le meilleur compromis entre MAE, biais et robustesse sur les pics tout en incluant un échantillon de validation d'une année complète et un test représentatif (1 an et 9 mois).

3.2 Variables explicatives

19 variables sont utilisées, réparties en cinq catégories :

Table 3 – Variables explicatives utilisées.

Catégorie	Variables
Historique de consommation	`consommation_j7`, `consommation_j1an`
Calendrier	`heure`, `jour_semaine`, `mois`, `weekend`, `est_ferie`
Températures	`temperature_moyenne`, `temperature_min`, `temperature_max`, `amplitude_thermique`
Degrés-jours	`HDD_moyen`, `HDD_min`, `HDD_max`
Moyennes glissantes	`TM_3j`, `TM_7j`, `HDD_3j`, `HDD_7j`
Froid	`duree_gel_min`

Le nom des features est inchangé d'un scénario à l'autre : seule la date de la météo jointe change (respectivement $J-1$ et $J+1$).

3.3 Modèles comparés

Benchmarks naïfs.

- $J-7$: consommation du même jour de la semaine précédente, même heure. Ce benchmark teste si la consommation est stable à l'échelle hebdomadaire, ce qui est vrai en régime normal mais faux lors des changements de régime (fêtes, vacances).
- $J-1$ **an** : consommation de la même date de l'année précédente, même heure. Ce benchmark teste si la consommation est stable à l'échelle annuelle, ce qui capture la saisonnalité mais ignore les tendances récentes.
- **Moyenne** : ce benchmark teste si la combinaison des deux précédents réduit la variance, ce qui est vrai en moyenne mais pas sur les cas atypiques.

Modèles d'apprentissage.

- **XGBoost** : gradient boosting. Ce modèle teste si un gradient boosting peut capturer les non-linéarités entre température et consommation, en particulier les effets de seuil du chauffage. Hyperparamètres optimisés par grid search sur la validation : `learning_rate` = 0,03, `max_depth` = 8, `min_child_weight` = 5, `subsample` = 0,6, `colsample_bytree` = 0,8, `gamma` = 0,1, `reg_alpha` = 0,1, `reg_lambda` = 1,0. Arrêt précoce sur la validation (patience 100).
- **Random Forest** : ce modèle teste si un ensemble d'arbres indépendants réduit la variance par rapport à XGBoost, au prix d'un biais plus élevé. Hyperparamètres : 300 arbres, feuilles minimales de 2, `max_features = sqrt`.
- **Ensemble** : en combinant les deux approches, ce modèle réduit l'erreur globale en exploitant leur complémentarité (variance vs biais). moyenne pondérée $\alpha \cdot RF + (1-\alpha) \cdot XGB$, avec α choisi sur la validation.

Référence externe. La prévision J-1 de RTE, récupérée via l'API éCO2mix temps réel, sert de référence haute.

3.4 Modélisation régionale et agrégation spatiale

En complément du modèle national, nous avons exploré une approche *spatiale* : entraîner un modèle par région métropolitaine (12 régions), puis agréger les prédictions individuelles par simple somme pour reconstruire une prévision nationale. L'objectif est double :

— **Tester si une décomposition spatiale apporte un gain** en capturant les dynamiques locales (météo régionale, structure industrielle, comportements de consommation) que l'agrégation nationale lisse.
— **Produire une visualisation opérationnelle** : une carte interactive des prévisions régionales est intégrée au dashboard Streamlit du projet (onglet « Carte régionale »).

Données régionales. Nous utilisons deux sources complémentaires :

— **Consommation régionale** : les datasets `eco2mix-regional-cons-def` (consolidé définitif) et `eco2mix-regional-tr` (temps réel), publiés par RTE.
— **Météo régionale** : pour chaque région, nous sélectionnons *un département de référence*. La météo du département est utilisée comme approximation de la météo régionale. Cette approximation s'explique par la contrainte de la taille des données (100 à 200 Mo par département) ainsi que la nécéssité de pondérer les départements par la population ce qui aurait nécessité une collecte supplémentaire de données. Nous retenons donc le département le plus peuplé de chaque région comme proxy, en supposant que sa météo reflète raisonnablement la dynamique régionale. Ce biais est explicitement mentionné dans l'analyse critique (Section 5.3), où nous discutons son impact sur la précision des modèles régionaux.

Protocole. Chaque modèle régional est entraîné selon la même structure que le modèle national avec un même split, mêmes hyperparamètres et mêmes 19 features. La prévision nationale *par somme* est obtenue en additionnant les 12 prévisions régionales.

3.5 Protocole d'évaluation

Les modèles sont comparés sur le *même test*, avec la *même information disponible*, et ce pour chacun des deux scénarios. Les métriques utilisées sont : MAE, RMSE, biais, erreur sur le pic journalier, erreur sur l'heure du pic, erreur sur la consommation journalière totale. Les performances sont ventilées par saison et par type de jour (ouvré, week-end, férié).

4. Résultats

4.1 Comparaison globale

Table 4 – Performances sur le test (Split 2, 2025–2026). Toutes les valeurs en MW.

	Opérationnel (météo $J-1$)			**Météo parfaite (météo $J+1$)**		
Modèle	**MAE**	**RMSE**	**Biais**	**MAE**	**RMSE**	**Biais**
Ensemble RF + XGB ($\alpha = 0{,}2$)	1,832	2,549	325	1,341	1,784	484
XGBoost seul	1,848	2,568	325	1,362	1,814	495
Random Forest seul	1,876	2,631	326	1,439	1,938	440
Benchmark moyenne	3,120	4,341	−77		*(identique)*	
Benchmark $J-7$	3,328	4,896	232		*(identique)*	
Benchmark $J-1$ an	4,075	5,604	−387		*(identique)*	
RTE $J-1$ (référence)	1,280	1,601		1,280	1,601	

Trois enseignements majeurs :

— Dans les deux scénarios, l'**ensemble RF + XGBoost** est le meilleur modèle, suivi de XGBoost seul, puis du Random Forest seul. Le classement est identique.
— Le scénario **météo parfaite** améliore la MAE de 26,8 % et la RMSE de 30,0 % par rapport au scénario opérationnel. C'est la valeur maximale qu'apporterait une météo parfaitement connue.

— Même en conditions **opérationnelles**, le modèle surpasse largement les benchmarks naïfs (−41 % de MAE vs benchmark $J-7$) et reste à un ratio de 1,43× de la prévision RTE.

4.2 Sélection du coefficient de pondération

L'ensemble optimise α (poids du Random Forest) sur la validation. Le tableau suivant présente les résultats pour les principales valeurs de α, dans les deux scénarios.

Table 5 – Recherche du coefficient de pondération de l'ensemble (validation 2024).

	Opérationnel		**Météo parfaite**	
α	**MAE val.**	**RMSE val.**	**MAE val.**	**RMSE val.**
0 ,0(XGBseul)	1,988	2,881	1,435	2,015
0 ,1	1,984	2,876	1,428	2,008
0 ,2	1,982	2,875	1,427	2,008
0 ,3	1,984	2,877	1,431	2,013
0 ,4	1,989	2,883	1,441	2,025
0 ,5	1,996	2,893	1,455	2,043
1 ,0(RFseul)	2,069	2,994	1,582	2,215

Le coefficient retenu est $\alpha = 0{,}2$ dans les deux scénarios : la contribution majoritaire vient de XGBoost, mais le Random Forest apporte une légère diversification qui réduit la variance.

4.3 Analyse par saison

Table 6 – MAE par saison (test). Toutes les valeurs en MW.

	Opérationnel		**Météo parfaite**	
Saison	**MAE**	**Biais**	**MAE**	**Biais**
Hiver	2,975	1,318	2,032	1,464
Printemps	1,731	199	1,310	152
Été	1,298	−385	1,024	24
Automne	1,425	392	1,041	487

L'hiver concentre les erreurs les plus fortes dans les deux scénarios. Le ratio MAE hiver/été est de 2,29× en opérationnel contre 1,99× en météo parfaite : la météo observée de $J+1$ réduit davantage les erreurs hivernales, ce qui est cohérent avec le poids du chauffage dans la consommation hivernale. Le biais du scénario opérationnel est *positif* en hiver (surestimation) et *négatif* en été (sous-estimation), tandis que le scénario parfait est systématiquement positif.

4.4 Analyse par type de jour

Table 7 – MAE par type de jour (test). Toutes les valeurs en MW.

	Opérationnel		**Météo parfaite**	
Type	**MAE**	**Biais**	**MAE**	**Biais**
Ouvré	1,848	445	1,370	596
Week-end	1,794	49	1,242	257
Férié	1,808	127	1,619	−74

En opérationnel, les jours fériés ne sont plus les plus difficiles : c'est un effet intéressant du proxy météo $J-1$, qui lisse les cas atypiques et rapproche les erreurs ouvré/week-end/férié. En météo

parfaite, les fériés redeviennent plus difficiles, ce qui reflète la spécificité de leurs profils de consommation.

4.5 Importance des variables

Table 8 – Importances des variables (XGBoost, top 5), par scénario. Valeurs en pourcentage.

Opérationnel (météo $J-1$)		**Météo parfaite (météo $J+1$)**	
Variable	**Imp.**	**Variable**	**Imp.**
`consommation_j7`	41,7	`consommation_j7`	37,6
`HDD_max`	25,0	`HDD_3j`	20,7
`temperature_max`	12,5	`HDD_7j`	13,2
`weekend`	4,3	`TM_3j`	5,3
`consommation_j1an`	2,7	`weekend`	4,4

Le modèle opérationnel mobilise massivement la variable `HDD_max` (25 %) et `temperature_max` (12 %), alors que le modèle en météo parfaite privilégie les *moyennes glissantes* (`HDD_3j`, `HDD_7j`, `TM_3j`) qui représentent 39 % à elles trois. Ce changement de profil révèle que, quand la météo du jour cible est parfaitement connue, le modèle peut exploiter directement les agrégats météo de $J+1$ au lieu de se reposer sur une valeur ponctuelle comme `HDD_max` du proxy $J-1$. La variable `consommation_j7` reste le pilier du modèle dans les deux cas (38 à 42 %).

4.6 Comparaison avec la somme des modèles régionaux (météo parfaite)

Nous avons exploré une approche spatiale alternative : entraîner un modèle par région métropolitaine (12 régions), puis sommer les prédictions individuelles. Cette étude a été menée sur le scénario à météo parfaite (avec la météo observée de $J+1$) ; sa transposition au scénario opérationnel donnerait des valeurs du même ordre.

Table 9 – Comparaison national vs somme régionale (météo parfaite). Toutes les valeurs en MW.

Approche	**MAE**	**RMSE**	**Biais**	**MAE pic**
Modèle national (Ensemble)	1,449	1,963	408	1,426
Somme des 12 modèles régionaux	1,521	2,059	467	1,489

La somme régionale est **légèrement moins précise** que le modèle national. Ce résultat s'explique par quatre facteurs : propagation d'erreurs positivement corrélées entre régions, moindre volume de données par région (12× moins d'observations), météo régionale approximée par un département unique, et effet de lissage implicite du modèle national.

5. Audit critique

5.1 Disponibilité de l'information

Table 10 – Disponibilité de chaque variable à 14h le jour J.

Variable	Source	Dispo.	Type	Risque de fuite
`conso_j7`	éCO2mix	$J-6$	Observé	Aucun (historique)
`conso_j1an`	éCO2mix	$J-365$	Observé	Aucun (historique)
Calendrier	Construite	J	Déterministe	Aucun
Scénario opérationnel (météo $J-1$) :				
`temperature_*`	Météo-France	$J-1$	Observé	Aucun (obs. disponible à 14h J)
`HDD_*`, `TM_*j`	Dérivée	$J-1$	Calculée	Aucun
`duree_gel_min`	Météo-France	$J-1$	Observé	Aucun
Scénario à météo parfaite (météo $J+1$) – non déployable :				
`temperature_*`	Météo-France	$J+1$	Observé	**Fuite**
`HDD_*`, `TM_*j`	Dérivée	$J+1$	Calculée	**Fuite**

La distinction entre les deux scénarios est structurante. Dans le **scénario opérationnel**, toutes les variables sont disponibles à 14h le jour J (la météo de $J-1$ est une observation entièrement connue, les lags de consommation remontent à au moins 6 jours, les variables calendaires sont déterministes). Aucune fuite n'existe.

Dans le **scénario à météo parfaite**, la météo observée de $J+1$ est utilisée *volontairement* comme information future. Ce scénario constitue une *fuite contrôlée*, uniquement destinée à mesurer la borne supérieure de performance. Il ne doit jamais être présenté comme déployable en conditions réelles.

Nuances sur le scénario opérationnel. Comme énoncé ci-dessus, nous utilisons Open-Meteo Forecast pour la prévision opérationnelle. Deux limites sont à signaler :

- **Agrégation spatiale** : Open-Meteo fournit la météo d'un point (Paris), alors que le modèle a été entraîné sur une moyenne nationale pondérée. Un biais systématique de 0,5 à $1°C$ est possible entre les deux sources.
- **Variable `duree_gel_min`** : non disponible via Open-Meteo, elle est mise à 0. Cela peut légèrement dégrader la prévision par rapport à la version entraînée.

Ces limites sont acceptables car le pipeline fonctionne de bout en bout et les prédictions restent cohérentes avec les performances observées.

5.2 Valeur ajoutée de la complexité

Étude d'ablation menée sur le scénario à météo parfaite, dans une version antérieure du pipeline. Les valeurs ci-dessous sont indicatives et n'ont pas été rejouées sur le scénario opérationnel.

Table 11 – Étude d'ablation. Impact sur la MAE (météo parfaite).

Configuration	**MAE (MW)**
Sans variables météo	2,944
Avec météo, sans `est_ferie`	1,703
Avec météo et `est_ferie`	1,650
Modèle complet (19 feat.)	1,449
Sans `est_ferie`	2,517
Sans vacances scolaires	1,458
Avec indicateur IPI	1,483
Avec pondération temporelle	1,623

Les enseignements majeurs :

— La **météo** est de loin la contribution la plus importante. Sans elle, la MAE double presque (2944 → 1703 MW, soit −42 %).

— Le `est_ferie` apporte un gain modeste sur la MAE globale (−3 %) mais **divise la MAE sur les fériés par 1,8** (4654 → 2517 MW). Son retrait fait exploser le biais sur les fériés (+2105 → +4517 MW), ce qui prouve son rôle critique sur les cas atypiques.

— Les **vacances scolaires** par zone n'apportent rien (dégradation marginale de 0,24 à 0,38 %). Explication : `consommation_j7` capture déjà implicitement les effets des vacances (si le même jour de la semaine précédente était en vacances, la consommation de référence est déjà ajustée).

— L'**IPI** (indice de production industrielle) dégrade la MAE (+2,5 %) mais améliore la détection des pics (+2,2 pts). Décision : rejeté pour la MAE globale.

— La **pondération temporelle** des observations (favoriser les récentes) ne réduit pas le biais (+687 → +701 MW) et dégrade la MAE (+0,9 %). Le biais n'est donc pas causé par une dérive temporelle.

5.3 Complexité spatiale : le cas des modèles régionaux

Nous avons montré (tableau 9) que la somme de 12 modèles régionaux est légèrement moins précise que le modèle national, alors qu'elle mobilise *12 fois plus de calcul*.

Interprétation. Cet écart de performance met en évidence trois limites structurelles de l'approche régionale telle que nous l'avons implémentée :

1. **Volume de données par région insuffisant** : chaque région dispose de 12 fois moins d'observations que la France entière. Pour 12 ans d'historique, cela représente ≈ 105 000 observations régionales contre ≈ 1,26 million au national. Les modèles régionaux sont donc mécaniquement moins bien entraînés.
2. **Représentativité météo limitée** : nous utilisons un seul département comme proxy de la météo régionale. Pour des régions comme Occitanie ou Nouvelle-Aquitaine, cette approximation est grossière. Utiliser une moyenne pondérée de plusieurs départements par région réduirait ce biais.
3. **Structure de dépendance spatiale ignorée** : les régions ne sont pas indépendantes. Par exemple, une vague de froid traverse le pays d'ouest en est.

Leçon méthodologique. Augmenter la finesse spatiale dégrade le ratio signal/bruit quand la quantité de données par sous-unité devient insuffisante.

5.4 Analyse de trois cas d'échec (scénario opérationnel)

Les cas ci-dessous sont extraits du **scénario opérationnel**, seul scénario déployable. Les dates et valeurs correspondent au test 2025–2026.

Cas 1 : 22 janvier 2025 – vague de froid hivernale. La MAE journalière atteint 10 018 MW (la plus forte du test). Le modèle prédit un pic à 84 311 MW pour un pic réel de 75 312 MW, soit une surestimation de 9 000 MW. La température moyenne est de 1,5°C avec $HDD = 16{,}5$. Ce cas illustre une **limite du proxy** $J-1$: la vague de froid s'est probablement intensifiée entre $J-1$ et $J+1$, et le modèle a extrapolé la rigueur du froid de $J-1$ à $J+1$, surestimant largement la consommation.

Cas 2 : 6 janvier 2026 – pic sous-estimé en hiver. La MAE journalière atteint 6 869 MW. Le pic réel est de 90 236 MW (record du test), prévu à 81 822 MW, soit une *sous-estimation* de 8 414 MW. La température moyenne est de $-1{,}3$°C avec $HDD = 19{,}3$. C'est l'inverse du cas précédent : le modèle, entraîné majoritairement sur 2012–2023 (hivers plus doux), n'a pas assez d'exemples de froid extrême récent pour généraliser correctement. Ce cas relève d'une **limite du protocole** (dérive climatique et baisse de la consommation) et d'une **limite d'apprentissage**.

Cas 3 : 26 mars 2026 – printemps. La MAE journalière atteint 8 598 MW, avec un biais *négatif* de $-206\,341$ MWh sur la journée. Le pic réel est de 65 363 MW, prévu à 55 656 MW. La température moyenne est de 10,6°C avec $HDD = 7{,}4$. Ce cas est à contre-courant de la tendance générale : le modèle *sous-estime* fortement, alors qu'il surestime en moyenne. Une vague de froid printanière tardive a probablement surpris le modèle, qui disposait d'une météo de $J-1$ plus douce. Ce cas combine une **rupture de régime** et une **limite du proxy météo**.

Enseignement. Ces trois cas montrent que le proxy météo $J-1$ introduit un biais *conditionnel* : quand la météo change rapidement entre $J-1$ et $J+1$, le modèle se trompe. À l'inverse, en météo parfaite, les erreurs sont plus faibles et plus uniformes : le cas le plus difficile du scénario parfait (2 mai 2025, MAE 5 431 MW) reste 45 % plus faible que le pire cas opérationnel.

5.5 Robustesse et conditions d'utilisation

- **Stabilité du classement.** L'ensemble RF + XGBoost reste devant XGBoost seul et Random Forest seul sur tous les sous-échantillons et dans les deux scénarios. Le classement est robuste.
- **Sensibilité au scénario.** Le gain de la météo parfaite est de +27 % de MAE et +30 % de RMSE. C'est l'ordre de grandeur de l'apport maximal d'une météo parfaite. En conditions réelles avec une prévision météo standard, on se situerait entre les deux bornes.
- **Sensibilité saisonnière.** L'hiver est systématiquement plus difficile que l'été (2,29× en opérationnel, 1,99× en météo parfaite).
- **Biais résiduel.** Le modèle opérationnel surestime la consommation de +325 MW en moyenne, avec un biais particulièrement élevé en hiver (+1318 MW). Le modèle en météo parfaite a un biais légèrement plus fort (+484 MW). Ces biais sont structurels (baisse récente de la consommation en France, hivers de test plus doux que la moyenne historique). Une correction naïve du biais dégrade les performances sur les pics.
- **Heures difficiles.** Les heures de pointe (7h–9h et 17h–20h) restent les plus difficiles dans les deux scénarios, avec des MAE opérationnelles de l'ordre de 1 900–2 150 MW contre 1 400–1 580 MW en météo parfaite. Les heures de nuit profonde restent les mieux prédites.

Conditions déconseillées. Nous déconseillons l'utilisation du système :

- lors d'épisodes météorologiques exceptionnels (vagues de froid précoces, canicules) où les prévisions météo elles-mêmes sont incertaines et où la persistance $J-1$ est trompeuse ;
- pour anticiper des ruptures structurelles (grèves, fermetures industrielles) ;
- pour des horizons au-delà de $J+1$, sans re-calibration.

6. Usage des agents conversationnels

Conformément au sujet, nous documentons trois exemples d'usage.

Exemple 1 : proposition conservée. Tâche demandée. Implémenter une fonction de calcul des degrés-jours de chauffage (HDD).
Proposition obtenue. Une fonction vectorisée avec NumPy, gérant les valeurs manquantes et les températures négatives.
Décision. Conservée après vérification manuelle sur 10 jours tests. Le calcul correspond à la définition classique $HDD = \max(0, 18 - T_{moy})$.
Vérification. Comparaison avec un calcul manuel et la documentation de l'INSEE.

Exemple 2 : proposition modifiée. Tâche demandée. Écrire la fonction de construction des features $J-7$ et $J-1$ an.
Proposition obtenue. Une fonction utilisant `pandas.DateOffset(years=1)`.
Décision. Modifiée. L'agent n'avait pas pris en compte le cas du 29 février. Ajout d'une gestion explicite avec fallback sur le 28 février et test de non-régression.
Vérification. Jeu de tests couvrant 2020 (bissextile) et 2021.

Exemple 3 : erreur détectée. Tâche demandée. Implémenter la lecture des données éCO2mix avec `requests`.
Proposition obtenue. Un code qui télécharge le CSV complet sans filtre.
Erreur détectée. Le code mettait plus de 3 minutes à s'exécuter. L'agent n'avait pas vu que l'API supporte un paramètre `where` côté serveur, réduisant la charge de 95 %.
Décision. Rejetée puis réécrite.
Vérification. Comparaison des temps d'exécution (180 s vs 4 s) et vérification que les données sont identiques.

7. Perspectives

Le modèle développé dans ce projet atteint des performances solides (MAE $\approx 1\,449$ MW, ratio 1,13× par rapport à la prévision J-1 de RTE), mais plusieurs pistes d'amélioration restent ouvertes. Nous les classons en cinq catégories : enrichissement des variables explicatives, modélisation de la pointe, architectures alternatives, post-traitement des prédictions, et granularité spatiale.

7.1 Enrichissement des variables explicatives

Le modèle utilise aujourd'hui un encodage *binaire* des jours fériés (`est_ferie`) et des weekends, ce qui est une simplification au regard de la complexité des comportements de consommation.

- **Encodage fin des jours fériés** : les jours fériés n'ont pas tous le même effet. Un *pont* (vendredi après un jeudi férié, lundi après un dimanche férié) a un profil proche d'un weekend, alors qu'un 1er mai ou un 25 décembre a un profil très atypique. La veille d'un jour férié est également particulière (activité réduite, mais pas nulle). Ajouter des indicateurs `est_pont`, `est_veille_ferie`, `type_ferie` (fixe / mobile / religieux) permettrait au modèle de distinguer ces situations. Notre split des données contient 45 jours fériés, dont beaucoup sont

précédés ou suivis de ponts, cette amélioration pourrait faire un peu baisser la MAE les jours fériés.

— **Vacances scolaires par zone** : l'ajout d'un indicateur de vacances par zone, non pas binaire mais par exemple pondéré par la population scolaire pourrait aussi améliorer les performances sur ces périodes. Le sujet est d'autant plus intéressant que les vacances d'hiver et de printemps sont décalées entre zones, ce qui crée des motifs de consommation distincts sur plusieurs semaines. Nous l'avons testé et cela a augmenté le biais, il y a peut-être une meilleure façon de transmettre l'information des vacances qu'en partageant de façon binaire si une zone est en vacances.

— **Événements exceptionnels** : les grèves (transport, raffineries, secteur public) et les événements sportifs majeurs (Coupe du monde, Jeux Olympiques, matchs de l'équipe de France) modifient ponctuellement la consommation. Une grève des transports peut faire baisser la consommation de bureau et augmenter la consommation résidentielle. Un match de l'équipe de France peut créer un pic de consommation à la mi-temps. Ces événements sont difficilement prévisibles, mais certains sont connus à l'avance (matchs programmés, préavis de grève). Les intégrer comme features binaires est une piste à coût faible tant qu'on peut trouver des api correspondantes à nos besoins.

— **Prévisions météo d'ensemble** : pour prédire la consommation j+1, nous utilisons actuellement une seule prévision météo (Open-Meteo), qui peut se tromper. Une approche plus robuste consiste à utiliser un ensemble de prévisions (par exemple, 10 scénarios issus de modèles météo différents) et à calculer la moyenne et l'écart-type de la consommation prévue. Cela permet non seulement d'améliorer la précision moyenne, mais aussi de quantifier l'incertitude sur la prévision finale, ce qui est très utile pour la gestion de réseau.

7.2 Modélisation spécifique des pointes

L'analyse des erreurs a montré que notre modèle sous-estime les pics (biais pic = −85 MW) et identifie l'heure de pointe dans seulement 64,7 % des cas.

— **Modèle dédié à la pointe** : entraîner un second modèle spécifiquement sur les heures de pointe (7h–9h et 17h–20h), avec des features enrichies (température ressentie, gradient de température sur 1h, indicateurs d'événements). Ce modèle serait utilisé en complément du modèle général, avec une pondération plus forte sur les heures de pointe. On peut attendre une amélioration du taux de pic correct.

— **Modèles par heure** : au lieu d'un modèle global avec `heure` comme feature, entraîner 24 modèles spécialisés (un par heure). Chaque modèle apprendrait les motifs spécifiques de son heure. Cette approche est classique en prévision de charge et donne souvent de meilleurs résultats, au prix d'une complexité accrue car il y aurait 24 modèles à maintenir.

— **Modèles par saison** : entraîner 4 modèles (hiver, printemps, été, automne) permettrait à chaque modèle d'apprendre les relations spécifiques à sa saison. L'hiver est dominé par le chauffage, l'été par la climatisation et l'éclairage. Le gain attendu pourrait être significatif sur les saisons extrêmes, mais la validation croisée serait plus complexe. Cette approche pose le problème du choix des dates de chaque saison. En effet, avec le réchauffement climatique, on peut observer des canicules dès les mois d'avril et de mai, des températures élevées en automne, ou d'autres décalages de saison. De plus, ces changements climatiques étant de plus en plus extrêmes avec le temps, les données historiques que nous avons ne permettent pas d'apprendre ces évolutions.

7.3 Architectures alternatives

Notre modèle final est un ensemble Random Forest + XGBoost. Plusieurs architectures méritent d'être testées.

— **LightGBM** : alternative à XGBoost, souvent plus rapide et aussi précise sur des données tabulaires. Il gère nativement les features catégorielles et utilise un algorithme de croissance d'arbre différent (leaf-wise vs level-wise). Le gain potentiel pourrait être relativement faire, de l'ordre de quelques pourcents de MAE au mieux, avec un temps d'entraînement potentiellement réduit.

— **Modèles de séries temporelles profondes** : les architectures LSTM, GRU et TFT (Temporal Fusion Transformer) sont conçues pour capturer des dépendances temporelles longues. Un LSTM pourrait apprendre des motifs que les arbres ne captent pas (par exemple, l'effet cumulé de plusieurs jours de froid). Le gain attendu est incertain sur ce type de données (les modèles à base d'arbres dominent souvent en prévision de charge tabulaire), mais l'exploration est scientifiquement intéressante.

— **Modèles hybrides** : combiner un modèle statistique classique (SARIMAX) avec un modèle d'apprentissage automatique (XGBoost) permet souvent de capturer à la fois les composantes linéaires (tendance, saisonnalité) et les non-linéarités. Le gain attendu est de -1 à -3 % de MAE.

7.4 Post-traitement des prédictions

Le post-traitement est une étape souvent négligée, mais à fort potentiel.

— **Correction du biais** : notre modèle a un biais résiduel de +408 MW (surestimation). Une correction naïve (soustraction du biais moyen) serait efficace en moyenne mais détériorerait les performances sur les pics, car le biais est plus fort en hiver et sur les heures de pointe. Une correction conditionnelle (par saison, par type de jour, par tranche horaire) serait plus robuste. Le gain attendu est une réduction du biais de 50 à 70 %, sans dégrader la MAE.

— **Calibration des pics** : entraîner un modèle spécifique sur les résidus des pics (écart entre pic prévu et pic réel), puis ajouter cette correction au modèle principal. Le gain attendu est une réduction de 15 à 25 % de l'erreur sur les pics.

— **Ensemble pondéré par le contexte** : au lieu d'un α fixe (0,2) pour l'ensemble RF + XGBoost, utiliser un α qui dépend du contexte (saison, type de jour, météo). Par exemple, $\alpha = 0{,}3$ en hiver et $\alpha = 0{,}1$ en été. Le gain attendu est de $-0{,}5$ à $-1{,}5$ % de MAE.

7.5 Granularité spatiale

Nous avons testé une première approche régionale qui, bien que fonctionnelle, est restée *légèrement moins précise* que le modèle national. Ce résultat ne remet pas en cause la pertinence de la décomposition spatiale, mais il ouvre plusieurs pistes pour l'améliorer.

— **Amélioration de la météo régionale.** Il faudrait utiliser plusieurs données de départements par région.

— **Modèles hiérarchiques.** Au lieu d'entraîner 12 modèles indépendants, entraîner un modèle national pour capturer la tendance commune, puis des modèles régionaux sur les résidus.

— **Modèles avec dépendance spatiale.** Les régions ne sont pas indépendantes. Un modèle de type *Graph Neural Network* (GNN) qui modélise explicitement les interactions entre régions voisines pourrait capturer les effets de propagation (vagues de froid, événements nationaux). L'apprentissage nécessiterait des données régionales à granularité plus fine (département, voire commune), ce qui dépasse le cadre actuel du projet.

— **Volume de données et profondeur temporelle.** Une limite fondamentale de l'approche régionale est le manque de données par région. Pour qu'un modèle régional atteigne la précision d'un modèle national il faudrait augmenter la profondeur temporelle.

7.6 Météo opérationnelle

À terme, l'utilisation d'une *vraie prévision météo de* $J+1$ (issue de Météo-France ou d'Open-Meteo Forecast) permettrait de se rapprocher du scénario à météo parfaite. Cet axe a été partiellement exploré via un script complémentaire (`06_prevision_operationnelle.py`) utilisant l'API Open-Meteo Forecast, mais n'a pas été évalué quantitativement dans ce rapport.

8. Conclusion

Nous avons construit une chaîne complète de prévision horaire de la consommation électrique en France métropolitaine. Le protocole respecte strictement la contrainte opérationnelle (aucune information postérieure à 14h le jour J n'est utilisée dans le scénario déployable). Deux scénarios ont été évalués : un scénario *opérationnel* avec météo de $J-1$ comme proxy, et un scénario à *météo parfaite* avec météo observée de $J+1$, servant de borne supérieure non déployable.

Le modèle final, un ensemble Random Forest + XGBoost avec $\alpha = 0{,}2$, atteint :

— **Scénario opérationnel** : MAE de 1 832 MW, RMSE de 2 549 MW, biais de +325 MW.

— **Scénario à météo parfaite** : MAE de 1 341 MW, RMSE de 1 784 MW, biais de +484 MW.

Le gain de la météo parfaite est de 26,8 % en MAE et 30,0 % en RMSE : c'est la valeur maximale qu'apporterait une prévision météo parfaitement connue. En conditions opérationnelles, le modèle surpasse le benchmark $J-7$ de 41 % et reste à un ratio de 1,43× de la prévision RTE.

L'analyse critique révèle plusieurs enseignements :

— La **météo** et les **retards de consommation** sont les variables les plus utiles.

— Le `est_ferie` réduit la MAE sur les fériés d'environ 30 %.

— Le biais positif persistant est structurel et ne se corrige pas par les hyperparamètres.

— L'hiver reste la saison la plus difficile (2,3× plus d'erreur qu'en été en opérationnel).

— L'approche régionale n'apporte pas de gain brut de précision.

Trois types d'échec se dégagent en opérationnel : biais du proxy météo lors des changements rapides de régime, sous-estimation des pics extrêmes récents, et ruptures de régime exceptionnelles (vagues de froid précoces ou tardives). La borne supérieure donnée par la météo parfaite reste elle-même imparfaite (MAE 1 341 MW), ce qui montre que la météo n'est pas la seule source d'erreur : la structure même de la consommation (comportements, aléas industriels) limite la précision atteignable.

Annexe : journal synthétique des usages d'agents

Tâche	**Proposition**	**Décision**	**Vérification**
HDD vectorisé	NumPy + gestion NaN	Conservée	Comparaison manuelle sur 10 jours
Feature $J-1$ an	`DateOffset(years=1)`	Modifiée	Tests 2020 & 2021
Lecture éCO2mix	Filtre client	Rejetée	Filtre serveur `where`, 180s → 4s
Split chronologique	70/15/15 proportionnel	Modifiée	4 splits comparés, Split 2 retenu
Optimisation α	Grid sur validation	Conservée	Recherche exhaustive 0 à 1
Ablation features	Retrait `est_ferie`	Rejetée	MAE fériés dégradée
Vacances scolaires	Ajout 3 indicateurs	Rejetée	MAE dégradée de +0,38%
Pondération temporelle	Poids linéaire croissant	Rejetée	MAE dégradée, biais inchangé
Jointure météo	Météo de J	Rejetée	Fuite identifiée, corrigée en $J-1$ / $J+1$

Bibliographie

— RTE, *éCO2mix* – Données de consommation électrique, https://odre.opendatasoft.com/.

— Météo-France, *Données climatologiques de base*, https://meteo.data.gouv.fr/.

— Open-Meteo, *Forecast API*, https://open-meteo.com/.

— T. Chen et C. Guestrin, *XGBoost : A Scalable Tree Boosting System*, KDD 2016.

— L. Breiman, *Random Forests*, Machine Learning, 2001.

— INSEE, *Indice de production industrielle* (utilisé en ablation puis abandonné).